

Glossaire IA

Les termes qui reviennent dans le projet, en une ligne chacun. De quoi parler le même langage dans l'équipe.

— LES BASES DU LLM

- LLM (Large Language Model)** — modèle qui prédit le token suivant ; génère du texte plausible, sans vérifier les faits ni « comprendre ».
- Token** — unité de texte ($\approx \frac{1}{4}$ de mot) que le modèle lit et génère ; on mesure le contexte et le coût en tokens.
- Inférence** — le fait d'exécuter le modèle pour produire une réponse (par opposition à l'entraînement).
- Fenêtre de contexte** — quantité maximale de tokens que le modèle « voit » d'un coup (prompt + historique + réponse) ; elle est finie.
- Température** — réglage de l'aléatoire des réponses : basse = stable et factuel (extraction), haute = créatif et variable.
- Embedding (vecteur)** — représentation numérique d'un texte qui capture son sens ; base de la recherche sémantique.

— PROMPT & CONTEXTE

- Prompt** — le texte fourni au modèle pour guider sa réponse.
- Prompt système** — instructions de cadrage (rôle, règles, ton, garde-fous) valables sur toute la conversation.
- Prompt engineering** — l'art de formuler des prompts clairs et efficaces (consignes, exemples, format attendu).
- Context engineering** — choisir précisément ce qu'on met (et ce qu'on retire) du contexte, pour maximiser la qualité au moindre coût.
- Few-shot** — donner quelques exemples dans le prompt pour montrer le comportement ou le format attendu.

— AGENTS & OUTILS

- Agent (IA)** — système où le LLM mène une tâche en plusieurs étapes et décide d'appeler des outils pour agir.
- Orchestration** — la logique qui enchaîne conversation, appels d'outils et réponses (dans n8n ou dans le code via le SDK).
- Tool / function calling** — le modèle déclenche une fonction (ex. `calculer_devis()`) avec des paramètres structurés ; c'est le code qui s'exécute.
- Sorties structurées** — forcer la réponse à respecter un schéma (JSON) pour obtenir des données fiables et typées.
- JSON Schema** — description formelle de la structure attendue d'une réponse (champs, types, champs obligatoires).
- Mémoire (de session)** — ce que l'agent retient d'un tour de conversation à l'autre (souvent via un identifiant de session).
- Streaming** — affichage de la réponse au fil de sa génération (token par token), pour une expérience fluide.
- MCP (Model Context Protocol)** — protocole standard pour connecter un agent à des outils et des données externes.

— CONNAISSANCE & DONNÉES

- RAG (Retrieval-Augmented Generation)** — aller chercher des extraits pertinents dans une base avant de répondre, pour ancrer la réponse sur des sources.
- Recherche sémantique** — retrouver une information par le sens (via embeddings) plutôt que par mots-clés exacts.
- Vector store (base vectorielle)** — base qui stocke des embeddings pour la recherche sémantique (ex. pgvector).
- Grounding (ancrage)** — fonder les réponses sur des données vérifiées plutôt que sur la « mémoire » du modèle.
- Lookup déterministe** — lecture exacte d'une valeur en base (≠ recherche sémantique) ; utilisé pour lire les règles de prix.

— FIABILITÉ, SÉCURITÉ & EXPLOITATION

- Hallucination** — réponse fluide et plausible, mais fausse ou inventée.
- Garde-fou (guardrail)** — règle ou mécanisme qui empêche un comportement indésirable (ex. le prix vient toujours du code).
- Déterministe / non-déterministe** — code : même entrée → même sortie ; LLM : sorties variables pour la même entrée.
- Human In The Loop (HITL)** — insérer une validation humaine aux étapes critiques (cas sensibles, échec d'outil).
- Prompt injection** — attaque où un texte malveillant détourne l'agent ; risque n°1 du classement OWASP des applications LLM.
- Observabilité / tracing** — tracer ce que fait l'agent (prompts, outils, tokens, coût, latence) pour déboguer et maîtriser les coûts.
- Évaluation (evals)** — mesurer la qualité d'un système non-déterministe (jeu de cas, jugement humain ou « LLM-as-judge »).
- Golden dataset** — jeu de cas de référence (entrées + sorties attendues) servant de base aux tests.
- Idempotence** — propriété d'une action qui, rejouée, ne produit pas d'effet en double (ex. une relance n'est pas envoyée deux fois).

— LA STACK DU PROJET

- Vibe coding** — développer en pilotant un assistant IA (Cursor, Claude Code) qui génère et édite le code.
- n8n** — outil d'automatisation par workflows ; son nœud « AI Agent » peut orchestrer l'agent.
- Vercel AI SDK** — bibliothèque TypeScript pour coder un agent (streaming, tool calling) dans Next.js.
- Webhook** — URL qui reçoit un événement déclencheur (ex. nouvelle demande) pour lancer un workflow.